


Data Visualization



Dr. Rosana El Jurdi

Dr. Rosana El Jurdi

R&D Engineer @ Euranova

PhD in Deep learning and Medical Image Processing

rosana.eljurdi@gmail.com

EUR
NOVA



Rosana EL JURDI

Euranova

Verified email at euranova.eu

Deep Learning Medical Image processing Image Registration Computer-aided Diagnostics

FOLLOW

GET MY OWN PROFILE

TITLE

CITED BY

YEAR

High-level Prior-based Loss Functions for Medical Image Segmentation: A Survey

R El Jurdi, C Petitjean, P Honeine, V Cheplygina, F Abdallah
arXiv preprint arXiv:2011.08018

108

2020

Bb-unet: U-net with bounding box prior

R El Jurdi, C Petitjean, P Honeine, F Abdallah
IEEE Journal of Selected Topics in Signal Processing 14 (6), 1189-1198

69

2020

A surprisingly effective perimeter-based loss for medical image segmentation

REL Jurdi, C Petitjean, P Honeine, V Cheplygina, F Abdallah
Medical Imaging with Deep Learning, 158-167

33

2021

CoordConv-unet: investigating CoordConv for organ segmentation

R El Jurdi, C Petitjean, P Honeine, F Abdallah
IRBM 42 (6), 415-423

18

2021

Organ segmentation in CT images with weak annotations: a preliminary study

R El Jurdi, C Petitjean, P Honeine, F Abdallah

9

2019

Cited by

All

Since 2020

Citations

261


261

h-index

6

i10-index

4



Public access

VIEW ALL



Rosana EL JURDI

FOLLOW


Euranova
Verified email at euranova.eu

Deep Learning Medical Image processing Image Registration Computer-aided Diagnostics

GET MY OWN PROFILE

Cited by

	All	Since 2020
Citations	261	26
h-index	6	
i10-index	4	



Public access

VIEW ALL

TITLE

CITED BY

YEAR

High-level Prior-based Loss Functions for Medical Image Segmentation: A Survey

108

2020

R El Jurdi, C Petitjean, P Honeine, V Cheplygina, F Abdallah
arXiv preprint arXiv:2011.08018

Bb-unet: U-net with bounding box prior

69

2020

R El Jurdi, C Petitjean, P Honeine, F Abdallah
IEEE Journal of Selected Topics in Signal Processing 14 (6), 1189-1198

A surprisingly effective perimeter-based loss for medical image segmentation

33

2021

REL Jurdi, C Petitjean, P Honeine, V Cheplygina, F Abdallah
Medical Imaging with Deep Learning, 158-167

CoordConv-unet: investigating CoordConv for organ segmentation

18

2021

R El Jurdi, C Petitjean, P Honeine, F Abdallah
IRBM 42 (6), 415-423


Organ segmentation in CT images with weak annotations: a preliminary study

9

2019



R El Jurdi, C Petitjean, P Honeine, F Abdallah

le cours, l'enseignant et l'entreprise



Who are We?

- propose des solutions basées sur les données pour de nombreux secteurs : HR / Retail / Telco / Aviation / Automotive / Bank & Insurance / Media / Pharma
- Nous travaillons sur trois grands axes de recherche (R&D):
 - Explainable AI
 - AI for Autonomous Systems
 - AI for medical imaging







l'organisation de cours

Tous les projets et les fiches de laboratoire doivent être soumis via un branch sur GitHub pour chaque étudiant→ [lien de project](#)

- excel slide to be filled
- le contenu de cours est dans une Github repo
 - envoye votre mail sur reljurdi@ext.esaip.org
 - familiarize yourself with Git : push , pull, commit ...
 - familiarize yourself with python
- le travaux de lab et TD doit être soumis dans une branch avec votre nom sur github.
- les projet aussi.
-

Util Nécessaire :




NetworkX
Network Analysis in Python




Introduction to Data Visualization

C'est quoi le visualization de données ?



Pourquoi on besoin l'outil de visualization des données ?


Introduction to Data Visualization



C'est quoi la visualization de données ?

Pourquoi on besoin l'outil de visualization des données ?

La visualisation est le processus qui transforme les données en représentation graphique interactive à des fins d'exploration, de confirmation ou de communication (résumé).



Introduction to Data Visualization

C'est quoi le visualization de données ?

La visualisation est le processus qui transforme les données en représentation graphique interactive à des fins d'exploration, de confirmation ou de communication (résumé).

Introduction to Data Visualization

C'est quoi le visualization de données ?

La visualisation est le processus qui transforme les données en représentation graphique interactive à des fins d'exploration, de confirmation ou de communication (résumé).

Introduction to Data Visualization

C'est quoi le visualization de données ?

La visualisation est le processus qui transforme les données en représentation graphique interactive à des fins d'exploration, de confirmation ou de communication (résumé).

Introduction to Data Visualization

C'est quoi le visualization de données ?

La visualisation est le processus qui transforme les données en représentation graphique interactive à des fins d'exploration, de confirmation ou de communication (résumé).

Introduction to Data Visualization


C'est quoi le visualization de données ?

La visualisation est le processus qui transforme les données en représentation graphique interactive à des fins d'exploration, de confirmation ou de communication (résumé).

Introduction to Data Visualization




- **Peintures rupestres** : Il y a environ 30 000 ans, les humains ont peint des centaines d'images dans des lieux tels que la grotte Chauvet en France. Ces dessins étaient probablement utilisés pour transmettre des informations importantes aux générations futures.



- **Peutinger Map** : une carte routière de près de 7 mètres de long, utilisée sous l'Empire romain, indiquant les routes principales et les monuments majeurs pour guider les commerçants tout au long de leur trajet.




Introduction to Data Visualization



la célèbre carte de Minard: illustre la campagne de Napoléon vers Moscou et sa retraite durant l'hiver en 1812.

Combien de variables voyez-vous dans cette figure ?

Introduction to Data Visualization



il y a six types de données en deux dimensions : le nombre de troupes de Napoléon, la distance parcourue, la température, la latitude et la longitude (ville et village) , la direction du déplacement, ainsi que la position par rapport à des dates spécifiques.

Introduction to Data Visualization





Image illustrant le destin de l'armée de Napoléon lors de son avancée vers Moscou et sa retraite durant l'hiver 1812

Quel est l'objectif poursuivi par cette visualisation ?

Introduction to Data Visualization

Combien de variables voyez-vous dans cette figure ?



Introduction to Data Visualization

I		II		III		IV	
X	Y	X	Y	X	Y	X	Y
10	8.04	10	9.14	10	7.46	8	6.58
8	6.95	8	8.14	8	6.77	8	5.76
13	7.58	13	8.74	13	12.7	8	7.71
9	8.81	9	8.77	9	7.11	8	8.84
11	8.33	11	9.26	11	7.81	8	8.47
14	9.96	14	8.1	14	8.84	8	7.04
6	7.24	6	6.13	6	6.08	8	5.25
4	4.26	4	3.1	4	5.39	19	12.5
12	10.8	12	9.13	12	8.15	8	5.56
7	4.82	7	7.26	7	6.42	8	7.91
5	5.68	5	4.74	5	5.73	8	6.89

un exemple pratique: 4 dataset

C'est
donné est
il identique
?

Introduction to Data Visualization

I		II		III		IV	
X	Y	X	Y	X	Y	X	Y
10	8.04	10	9.14	10	7.46	8	6.58
8	6.95	8	8.14	8	6.77	8	5.76
13	7.58	13	8.74	13	12.7	8	7.71
9	8.81	9	8.77	9	7.11	8	8.84
11	8.33	11	9.26	11	7.81	8	8.47
14	9.96	14	8.1	14	8.84	8	7.04
6	7.24	6	6.13	6	6.08	8	5.25
4	4.26	4	3.1	4	5.39	19	12.5
12	10.8	12	9.13	12	8.15	8	5.56
7	4.82	7	7.26	7	6.42	8	7.91
5	5.68	5	4.74	5	5.73	8	6.89


un exemple pratique:

Chacun de ces ensembles de données a le même nombre d'entrées, la même moyenne de x, la même moyenne de y, la même variance de x, la même variance de y, la même corrélation et la même équation de régression linéaire.


C'est donné est il identique ?

Descriptive Statistics	
N	11
Mean x	9
Mean y	8
Variance x	11
Variance y	4.12
Correlation x&y	0.816
Linear regression	$y=3.00 + 0.500x$


Introduction to Data Visualization



Introduction to Data Visualization




Introduction to Data Visualization




Introduction to Data Visualization

Anscombe Quartet









Introduction to Data Visualization

Anscombe Quartet



Introduction to Data Visualization





Basic Visualization Techniques !

Méthodes fondamentales pour représenter les données visuellement

[Data 2 viz](#) → follow the link for more info.

Histograms


Un **histogramme** d'une caractéristique (ou d'une variable) est un graphique qui permet de visualiser la distribution des valeurs de cette caractéristique au sein d'un ensemble de données. Un histogramme illustre la distribution d'une série de mesures (tailles, notes, températures...).

Comment interprète-t-on un histogramme ?

↔ **Axe horizontal (abscisses):** Montre les différentes valeurs possibles (classes ou *bins*).

↑↓ **Axe vertical (ordonnées):** Nombre (fréquence) de points de données dont la valeur se situe dans l'intervalle correspondant de l'axe horizontal. La hauteur des barres indique cette quantité.

▮ **Barres:** Chaque barre représente un intervalle de valeurs. La hauteur de la barre est proportionnelle au nombre de données dans cet intervalle (barres hautes = plus de données, barres basses = moins de données).



Bar Plots

Un bar plot représente les variables catégorielles. Plus précisément, les “bar plots” sont utilisés pour illustrer la relation entre une variable catégorielle et une variable numérique. Par contre, **Les histogrammes**, sont des diagrammes qui montrent la distribution d’une variable numérique continue.

Comment interprète-t-on un bar plot ?

- ➔ **Axe horizontal (abscisses)** : Montre les différentes catégories ou groupes possibles. Ce sont des étiquettes discrètes et distinctes.
- ↕ **Axe vertical (ordonnées)** : Montre la valeur numérique associée à chaque catégorie. Cela peut être un compte, une mesure, une quantité, etc.
-  **Barres** : Chaque barre représente une catégorie.
- La hauteur (ou la longueur, si les barres sont horizontales) de la barre est proportionnelle à la valeur numérique pour cette catégorie.
 - Barres plus hautes = valeurs plus grandes ; barres plus courtes = valeurs plus petites.

Comparaison : Les graphiques à barres sont excellents pour comparer les valeurs entre différentes catégories.



Building Blocks of visualization !


les éléments fondamentaux de la visualisation

les éléments fondamentaux de la visualisation

Marque

Echelles

- Les marques sont les éléments graphiques de base, avec une **géométrie** définie (forme visuelle), que vous utilisez pour représenter visuellement vos observations (items) ou les liens.
- Pensez-y comme aux formes ou symboles fondamentaux qui apparaissent sur votre graphique.





les éléments fondamentaux de la visualisation

Marque

Echelles

- Les marques sont les éléments graphiques de base, avec une **géométrie** définie (forme visuelle), que vous utilisez pour représenter visuellement vos observations (items) ou les liens.
- Pensez-y comme aux formes ou symboles fondamentaux qui apparaissent sur votre graphique.






les éléments fondamentaux de la visualisation

Marque

Echelles


- Les marques sont les éléments graphiques de base, avec une **géométrie** définie (forme visuelle), que vous utilisez pour représenter visuellement vos observations (items) ou les liens.
- Pensez-y comme aux formes ou symboles fondamentaux qui apparaissent sur votre graphique.



les éléments fondamentaux de la visualisation

Marque

- Les marques sont les éléments graphiques de base que vous utilisez pour représenter visuellement vos observations (items) ou les liens.
- Pensez-y comme aux formes ou symboles fondamentaux qui apparaissent sur votre graphique.



scatter plots

Chaque point dans le "scatter plots" représente une ligne de vos données avec ses valeurs x et y correspondantes.

Echelles

	x	y	group
0	2.764052	2.883151	A
1	1.400157	-0.347759	A
2	1.978738	-0.270485	A
3	3.240893	1.969397	A
4	2.867558	-0.173123	A
...	...	...	...
295	8.926075	2.379236	C
296	8.341447	1.529967	C
297	8.485766	1.783269	C
298	7.981958	1.069843	C
299	8.922145	1.821411	C


300 rows × 3 columns

les éléments fondamentaux de la visualisation

Marque (observation)

bar plots

Dans un "bar graph", chaque barre (un rectangle) représente généralement une valeur agrégée pour une catégorie.




	Category	Sales	Transaction_ID
0	Electronics	60000	1
1	Clothing	30000	2
2	Books	12000	3
3	Electronics	45000	4
4	Home Goods	25000	5
5	Clothing	55000	6
6	Food	18000	7
7	Books	28000	8
8	Home Goods	40000	9
9	Electronics	35000	10
10	Food	22000	11

les éléments fondamentaux de la visualisation

Marque (lien)

Certain Des marques spécifiques sont destinées à représenter les relations ou les connexions entre des points de données.

Un exemple courant est une marque linéaire dans un graphique linéaire, où la ligne relie une série de points de données, montrant une tendance dans le temps ou une autre variable continue.




les éléments fondamentaux de la visualisation

Marque (lien)

Certaines marques spécifiques sont destinées à représenter les relations ou les connexions entre des points de données.

Un exemple courant est une marque linéaire dans un graphique linéaire, où la ligne relie une série de points de données, montrant une tendance dans le temps ou une autre variable continue.

Les graphes de réseaux utilisent également des marques linéaires pour représenter les connexions entre les nœuds (qui sont eux-mêmes souvent représentés par des marques circulaires).



les éléments fondamentaux de la visualisation

Marque



Echelles

les éléments fondamentaux de la visualisation

Echelles

- Les échelles sont des fonctions qui mettent en correspondance les valeurs de vos “dataset” avec les propriétés visuelles des marques.
- **Les échelles** déterminent comment les valeurs de données abstraites sont traduites en caractéristiques visuelles concrètes que nous pouvons voir et interpréter.
- Le choix d'une échelle appropriée en visualisation de données est crucial pour représenter fidèlement vos données, éviter les mauvaises interprétations et communiquer efficacement les informations clés.


les éléments fondamentaux de la visualisation

Echelles

Considérez l'étude suivante : **Billets de service client**. Nous aurions besoin d'étudier l'évolution du nombre de nouveaux tickets de service client du produit A par rapport au produit B sur 12 mois.

product_a_sales : Représente le nombre de nouveaux tickets de service client ouverts chaque mois pour le « Produit A » (par exemple, une application logicielle).

product_b_sales : Représente le nombre de nouveaux tickets de service client ouverts chaque mois pour le « Produit B » (par exemple, un appareil matériel).



1 à 12 représentent les mois d'une année.


les éléments fondamentaux de la visualisation

Echelles

Considérez l'étude suivante : **Billets de service client**. Nous aurions besoin d'étudier l'évolution du nombre de nouveaux tickets de service client du produit A par rapport au produit B sur 12 mois.

Visualization 1 (Misleading Scale): Dans ce cas, nous avons choisi de limiter l'échelle de l'axe des ordonnées à 40.

- **Mauvaise interprétation:** "Produit A a plus de problèmes." Allocation de personnel déséquilibrée.
- **Problème caché:** Forte augmentation des tickets Produit B plus tard, signe de problèmes potentiels.




les éléments fondamentaux de la visualisation

Echelles

Considérez l'étude suivante : **Billets de service client**. Nous aurions besoin d'étudier l'évolution du nombre de nouveaux tickets de service client du produit A par rapport au produit B sur 12 mois.

Visualization 2 (Accurate Representation): Dans ce cas, nous avons choisi une Axe Y complet (0 à 100) pour visualiser la tendance complète du volume de tickets.

- **Interprétation :** Image plus précise. Volume modéré et stable pour Produit A (problèmes constants mais stables). Forte préoccupation pour Produit B en fin d'année, nécessitant une attention particulière.
- **Action suggérée :** Investigation de la cause de la forte augmentation des tickets Produit B.



les éléments fondamentaux de la visualisation


Echelles

Considérez l'étude suivante : **Billets de service client**. Nous aurions besoin d'étudier l'évolution du nombre de nouveaux tickets de service client du produit A par rapport au produit B sur 12 mois.

Visualization 3 (Logarithmic Scale): L'échelle logarithmique met l'accent sur le taux d'augmentation des tickets. Une pente plus abrupte indique une accélération plus rapide des problèmes.

Interprétation : Le volume de tickets du Produit B n'augmente pas seulement, il augmente à un rythme accéléré au milieu de l'année. Cela suggère fortement une aggravation du problème, peut-être un bug logiciel introduit lors d'une "update", par exemple.

Action suggérée : Investigation et action urgentes nécessaires pour éviter une dégradation supplémentaire.



les éléments fondamentaux de la visualisation

Echelles Résumé:

1. Représentation précise de données:

- **Proportionnalité** : Une échelle bien choisie garantit que la représentation visuelle est directement proportionnelle aux valeurs de données. Une échelle inappropriée peut manipuler ces proportions → conclusions incorrectes .
- **Éviter les Visualisations Trompeuses** : Des échelles incorrectes peuvent exagérer de petites différences ou masquer de grandes différences. Par exemple: commencer l'axe des y d'un graphique à barres à une valeur autre que zéro peut faire apparaître les différences entre les barres comme beaucoup plus significatives qu'elles ne le sont en réalité.

2. Clear Communication of Insights:

- **Highlighting Patterns and Trends (tendance et évolution)** : L'échelle appropriée peut révéler efficacement les tendances, les schémas et les relations dans les données. Une échelle mal choisie pourrait atténuer des variations intéressantes → plus difficile la distinction des informations clés significatives.
- **Facilitation des Comparaisons** : une échelle cohérente et appropriée permet des comparaisons visuelles faciles et précises. Si les échelles sont incohérentes ou mal définies, ces comparaisons deviennent difficiles et potentiellement trompeuses.

3. Considérations Éthiques : Manipuler intentionnellement les échelles pour créer une impression souhaitée est contraire à l'éthique et peut gravement nuire à la crédibilité de la visualisation et du présentateur.

Session 1 - Introduction to pandas and basic visualization !

Introduction to Histograms lab 1

Introduction to bar plots lab 2

Global Patterns and Summary Statistics

Tendances global et statistiques

Global Patterns and statistical reasoning

Impact des graphiques sur le raisonnement :

- Une surcharge d'informations dans un graphique peut entraîner une confusion chez le lecteur, rendant l'interprétation difficile.
- Une visualisation excessivement simpliste peut ne pas avoir l'impact souhaité, en négligeant des détails importants.

Objectif : Acquérir des connaissances pratiques sur l'interprétation des différentes techniques de visualisation, leurs forces et leurs limites.

Global Patterns and statistical reasoning

Visualisations : Impact et Interprétation

- Surcharge vs. Simplification :
 - Trop d'informations : Confusion, interprétation erronée.
 - Trop simple : Perte de nuances, impact réduit.
- Objectif :
 - Maîtriser l'interprétation des techniques de visualisation.
 - Identifier point forte et limites de chaque type de graphique.
- Types de Visualisations Clés :
 - **Distribution des caractéristiques** : Histograms (variabilité individuelle).
 - **Relations entre caractéristiques** : Scatter plots, line plots, heatmaps (variations croisées).
 - **Tendances globales** : Détection d'anomalies facilitée.
- Challenge :
 - Le choix du graphique influence la compréhension du lecteur.
 - Une mauvaise visualisation peut induire de fausses conclusions.

Example:

Le dataset 'mpg', abréviation de 'miles per gallon' est un dataset classique utilisé pour l'analyse statistique et machine learning. Il contient des informations sur divers modèles de voitures de la fin des années 1970 et du début des années 1980. L'objectif principal de ce dataset est d'explorer la relation entre les caractéristiques des véhicules et leur efficacité énergétique.



	mpg	cylinders	displacement	horsepower	weight	acceleration	model_year	origin	name
0	18.0	8	307.0	130.0	3504	12.0	70	usa	chevrolet chevelle malibu
1	15.0	8	350.0	165.0	3693	11.5	70	usa	buick skylark 320
2	18.0	8	318.0	150.0	3436	11.0	70	usa	plymouth satellite
3	16.0	8	304.0	150.0	3433	12.0	70	usa	amc rebel sst
4	17.0	8	302.0	140.0	3449	10.5	70	usa	ford torino




Objectif:




- Analyser les facteurs qui influencent l'efficacité énergétique.
- Construire des modèles prédictifs pour le MPG.
- Explorer les relations entre les différentes caractéristiques des véhicules.

Example:

Plotting weight of car vs miles per gallon value



scatter plots : une corrélation négative générale entre le poids du véhicule et le MPG (miles par gallon). Cependant, il est difficile de voir la densité précise et les motifs.



hexbin plots : Le hexbin révèle une forte concentration de véhicules dans plusieurs endroits notamment evidence de la présence d'un groupe distinct de véhicules légers avec un MPG très élevé

Scatter plots

Un **scatter plot** est un graphique simple qui présente les valeurs de deux caractéristiques/features/columns dans un dataset. Les **scatter plots** peuvent aider à révéler les relations entre différentes caractéristiques des données et à identifier les tendances.

Comment interprète-t-on un scatter plot ?

↔ **Axe horizontal (abscisses):** Représente les valeurs d'une première feature.

↑↓ **Axe vertical (ordonnées):** Représente les valeurs d'une seconde feature.

● **Points:** La position de chaque point indique la valeur simultanée des deux features pour une observation donnée.




Tendances:

- Une tendance linéaire suggère une corrélation entre les variables.
- Des groupements de points peuvent indiquer des sous-populations.
- Des points isolés (outliers) peuvent signaler des valeurs atypiques.



Correlations:

- Une corrélation positive montre que quand X augmente, Y augmente.
- une corrélation négative montre que quand X augmente, Y diminue.
- une dispersion aléatoire des points indique une absence de corrélation





Hexbon Plots

Un **hexbin plot** (hexagonal binning plot) est un graphique plus sophistiqué que les scatter plots, utilisable lorsque les variables x et y sont numériques.

Comment interprète-t-on un hexbin?

- **Hexagones :**
 - Chaque hexagone représente une zone dans l'espace des deux variables.
 - La couleur ou l'intensité de la couleur de l'hexagone indique la densité des points de données dans cette zone.
 - Plus la couleur est foncée, plus il y a de points dans l'hexagone, et donc une plus grande densité de données dans cette zone de l'espace des 2 variables.
- **Tendances :**
 - Les zones de forte densité (hexagones plus foncés) révèlent les zones où les données sont concentrées.
 - Les motifs de densité peuvent suggérer des relations ou des groupements dans les données, qui peuvent être cachés dans un scatter plot en raison du sur-traçage (trop de points proches les uns des autres qui obscurcissent la visualisation).
- **Correlations :**
 - les hexbins peuvent indiquer des corrélations en montrant où les densités de données sont les plus élevées.
 - Les zones de faible densités permettent quand a elle de voir les endroits où il y a un manque de corrélation.





Line Plots

Un **line plots** montrent l'évolution d'une variable continue en fonction d'une variable discrète,

Line Plots :

- Regrouper les données en fonction des valeurs de l'axe des abscisses, calculer un agrégat (généralement la moyenne) pour chaque groupe, puis relier ces moyennes par des segments de droite, créant ainsi une tendance continue
- calcule et affiche les intervalles de confiance autour de la moyenne, ce qui peut influencer les limites de l'axe des ordonnées
- met l'accent sur les tendances, tandis que les nuages de points soulignent la distribution des données.
-





Contour Plots

Un **line plots** montrent l'évolution d'une variable continue en fonction d'une variable discrète,


Contour Plots :

- Regrouper les données en fonction des valeurs de l'axe des abscisses, calculer un agrégat (généralement la moyenne) pour chaque groupe, puis relier ces moyennes par des segments de droite, créant ainsi une tendance continue
- calcule et affiche les intervalles de confiance autour de la moyenne, ce qui peut influencer les limites de l'axe des ordonnées
- met l'accent sur les tendances, tandis que les nuages de points soulignent la distribution des données.



Heatmaps

Un **heatmap** est une représentation visuelle d'une caractéristique numérique continue spécifique en fonction de deux autres caractéristiques discrètes (soit catégoriques, soit numériques discrètes) dans l'ensemble de données




	year	month	passengers
0	1949	Jan	112
1	1949	Feb	118
2	1949	Mar	132
3	1949	Apr	129
4	1949	May	121
...	...	...	...
139	1960	Aug	606
140	1960	Sep	508
141	1960	Oct	461
142	1960	Nov	390
143	1960	Dec	432

144 rows × 3 columns

Box Plots

Un **boxplot** est une représentation visuelle des valeurs statistiques

- est une manière standardisée d'afficher la distribution des données basée sur un résumé à cinq chiffres : minimum, premier quartile (Q1), médiane (Q2), troisième quartile (Q3) et maximum.
- Il représente visuellement la tendance centrale (médiane), la dispersion (écart interquartile) et l'asymétrie des données, et aide à identifier les valeurs aberrantes potentielles.



Lab 3

Analyse de scénarios et génération de visualisations appropriées



Mission



Analyser le jeu de données "120 ans d'histoire olympique" pour identifier les cinq disciplines sportives ayant attribué le plus grand nombre de médailles en 2016, puis réaliser les analyses suivantes :



Générer un graphique indiquant le nombre de médailles décernées pour chacun de ces cinq sports en 2016.



Tracer un graphique représentant la distribution de l'âge des médaillés dans ces cinq sports en 2016.



Déterminer quelles équipes nationales ont remporté le plus grand nombre de médailles dans ces cinq sports en 2016.



Observer la tendance du poids moyen des athlètes (hommes et femmes) médaillés dans ces cinq sports en 2016.



Étapes clés de l'exercice



1. Télécharger le jeu de données et le formater sous forme de DataFrame pandas.



2. Filtrer le DataFrame pour ne conserver que les lignes correspondant aux médaillés de l'année 2016.



3. Calculer le nombre de médailles attribuées en 2016 pour chaque sport.



4. Lister les cinq premiers sports selon le nombre de médailles. Filtrer à nouveau le DataFrame pour ne garder que les données relatives à ces cinq sports en 2016.



5. Générer un diagramme à barres (bar plot) du nombre d'entrées correspondant à chacun de ces cinq sports.



6. Générer un histogramme pour la variable "Age" de tous les médaillés des cinq sports sélectionnés (2016).



7. Générer un diagramme à barres indiquant le nombre de médailles remportées par chaque équipe nationale dans ces cinq sports en 2016.



8. Générer un diagramme à barres indiquant le poids moyen des athlètes, classés par sexe, ayant remporté une médaille dans ces cinq sports en 2016.

Lab 4 : Analyse du jeu de données MPG

Dans ce tutoriel, nous allons explorer en détail le jeu de données "mpg". Ce jeu de données, initialement publié par la bibliothèque StatLib de l'Université Carnegie Mellon et désormais disponible dans la bibliothèque Seaborn. L'objectif de ce tutoriel est d'explorer la relation entre la consommation de carburant (Miles Gallon, ou MPG) et diverses autres caractéristiques de ce jeu de données.



Caractéristiques Discrètes

3 variables catégorielles pour analyser des groupes ou des classifications.



Caractéristiques Continues

5 variables numériques pour examiner des relations et des tendances quantitatives.

Visualization of temporal data.

Visualisation de données temporelles

Temporal Data

Les données temporelles sont un type de données qui dépend du temps et dans lesquelles le temps est explicitement rapporté comme une variable. Pour ce type de données, le temps est une dimension inhérente et est toujours associé aux données.

Types des données Temporelle:

- **Événements** : Changements dans l'état d'un objet à un moment précis (par exemple, un tweet publié, un e-mail envoyé).
- **Mesures** : Valeurs enregistrées au fil du temps, cruciales pour la prévision et la détection d'anomalies (par exemple, données de capteurs, valeurs boursières).
- **Séquentiel** : Le temps considéré comme des valeurs linéaires continues, par exemple l'enregistrement des étapes pendant l'exercice.
- **Cyclique** : Le temps vu comme des périodes fixes récurrentes utilisées pour les comparaisons (par exemple, les ventes mensuelles, le changement de température annuel).
- **Hiérarchique** : Le temps structuré en niveaux pour visualiser les données à différentes granularités (par exemple, évaluation de la performance d'une athlète dans l'année, dans la saison, dans chaque marathon).

	Year	TemperatureChange
0	1880	-0.07
1	1881	-0.06
2	1882	-0.08
3	1883	-0.12
4	1884	-0.29

Fig: rate of temperature change (ice melting) in Greenland.

Dans les visualisations de données temporelles, le temps est tracé sur l'axe des x, et les autres caractéristiques de l'ensemble de données sont tracées sur l'axe des y.

Temporal Data

la relation entre les données temporelles (Temporal Data) et les séries chronologiques (Time-Series Data).

	Year	TemperatureChange
0	1880	-0.07
1	1881	-0.06
2	1882	-0.08
3	1883	-0.12
4	1884	-0.29



Fig: rate of temperature change (ice melting) in Greenland (example of time series) .

Fig: June 15, 2018 (L) and April 6, 2019 ® (example of temporelle data)

- Les données de séries chronologiques impliquent des observations enregistrées à des intervalles de temps constants.
- Les données temporelles incluent des observations liées au temps, mais ces intervalles peuvent être irréguliers.
- Par conséquent, toutes les données de séries chronologiques sont des données temporelles, mais toutes les données temporelles ne sont pas des données de séries chronologiques.

Exemples de données temporelles : Météo (hazard) ,Dossiers médicaux : Consultations (date et heure), diagnostics (date), hospitalisations (date d'entrée et de sortie), vaccinations (date).

Exemples de séries chronologiques : Finance (sales) , Météo : Température horaire

Visualization of temporal data.

Lab 5 et lab 6 : Visualisation de données temporelles

Visualization of text documents.

Text Data

Contrairement aux données numérique, le texte est plus complexe et intéressant à montrer avec des présentation visuelle.

Challenges of Visualizing text data

- **High Dimensionality:** Le texte a énormément de "dimensions" possibles (mots uniques).
- **Unstructured and Variable:** Le même sens peut être exprimé de plein de manières différentes.
- **Semantic Complexity and Context:** Le sens d'un mot dépend beaucoup du texte autour.
- **Granularity Issues:** On peut analyser le texte à différents niveaux (mots, phrases, documents).
- **Sparsity:** Les façons de représenter le texte ont souvent beaucoup de zéros.
- **Stop Word Problem:** Les mots courants peuvent cacher les motifs importants.
- **Visualizing Relationships:** Montrer les liens entre les éléments du texte est plus compliqué.
- **Need for Abstraction/Aggregation:** Le texte à l'état brut "raw text" nécessite fréquemment d'être traité avant sa visualisation.

Text Data

Unlike numerical data, text presents unique challenges and opportunities for visual representation:

- **Exploratory Data Analysis of Large Text Datasets:** Lorsqu'on est confronté à une masse d'informations textuelles (avis de clients, publications sur les réseaux sociaux, articles de presse, travaux de recherche), la visualisation constitue un outil précieux pour une première exploration.
- **Pattern Recognition:** Elle aide à identifier les tendances et les relations difficiles à percevoir dans le texte brut. Exemple : Un graphique de réseau révèle les liens entre les mots qui co-occurrent.
- **Improved Communication:** Les éléments visuels sont plus efficaces pour transmettre des informations à un large public. Exemple : Un "pie chart" de sentiments montre clairement le ton général des avis clients.
- **Facilitates Data Exploration:** Les visualisations interactives permettent aux utilisateurs d'explorer et de comprendre les données textuelles. Exemple : un utilisateur peut filtrer un graphe de réseau pour se concentrer sur des relations spécifiques.
- **Aids Decision-Making:** Des visualisations claires fournissent des informations utiles pour prendre des décisions éclairées.
- Exemple : identifier les thèmes clés dans les retours clients peut orienter le développement d'un produit.

Key Takeaway: Text data visualization transforms complex text into easily understandable and actionable insights.

Text data visualization Libraries :

Text Data

Exploratory Data Analysis of Large Text Datasets:



Pattern Recognition: Il aide à identifier les tendances et les relations difficiles à percevoir dans le texte brut. Exemple : Un graphique de réseau révèle les liens entre les mots qui co-occurent.



Improved Communication: Les éléments visuels sont plus efficaces pour transmettre des informations à un large public. Exemple : Un "pie chart" de sentiments montre clairement le ton général des avis clients.



Facilitates Data Exploration: Les visualisations interactives permettent aux utilisateurs d'explorer et de comprendre les données textuelles. Exemple : un utilisateur peut filtrer un graphe de réseau pour se concentrer sur des relations spécifiques.



Aids Decision-Making: Des visualisations claires fournissent des informations utiles pour prendre des décisions éclairées. Exemple : identifier les thèmes clés dans les retours clients peut orienter le développement d'un produit.



Key Takeaway: Text data visualization transforms complex text into easily understandable and actionable insights.

Text data visualization Libraries :

Unlike numerical data, text presents unique challenges and opportunities for visual representation:

Visualizing Textual Importance Through Frequency.



Definition: A visual representation of text where word size indicates frequency, offering a quick and intuitive summary of key patterns.



- Takes text as input and calculates word frequencies.
- Arranges words in a visually appealing cloud, size proportional to frequency.
- Offers customization (shape, colors, stopwords).



Pros: Easy to create, visually engaging, basic customization.



Key Takeaway: Word clouds provide a quick, engaging visual summary of word frequency but lack deep analytical depth.

Textblob

Définition: TextBlob is a popular Python library for processing textual data. It can be used for many natural language processing (NLP) tasks.

Functionalities:

- sentiment analysis.
- word counts
- Lemmatization Reducing words to their base or dictionary form (lemma)
- Noun phrase parsing
- assigning a grammatical category (like noun, verb, adjective, adverb, etc.)
- Tokenization (Word and Sentence Tokenization):

Textblob

Définition: TextBlob is a popular Python library for processing textual data. It can be used for many natural language processing (NLP) tasks.



```
# Sample reviews with associated sentiment (you'd typically get this from a sentiment analysis tool)
reviews_with_sentiment = [
    ("This product is absolutely amazing! I love it so much.", "positive"),
    ("The features are fantastic and it works perfectly.", "positive"),
    ("I am extremely happy with this purchase. Highly recommended!", "positive"),
    ("What a terrible experience. The product broke after just one use.", "negative"),
    ("This is the worst item I have ever bought. Complete waste of money.", "negative"),
    ("I was so disappointed. It didn't meet my expectations at all.", "negative"),
    ("It's okay, but nothing special. Could be better.", "neutral"),
    ("Good value for the price. I'm satisfied.", "positive"),
    ("The customer service was awful and unhelpful.", "negative"),
    ("Really impressed with the quality and performance!", "positive"),
    ("Meh, it's alright. Not great, not bad.", "neutral"),
    ("Avoid this product at all costs! Seriously flawed.", "negative"),
    ("So glad I bought this! It has made my life easier.", "positive"),
    ("The setup was confusing and the instructions were unclear.", "negative"),
    ("A solid product that does exactly what it says.", "positive"),
```

```
]
```

Textblob

Sentiment analysis :

```
for review_text, provided_sentiment in reviews_with_sentiment:
    # Create a TextBlob object
    blob = TextBlob(review_text)

    # Get the polarity score
    polarity = blob.sentiment.polarity

    # Determine sentiment based on polarity
    if polarity > 0.1: # We can set a threshold, e.g., > 0.1 for positive
        textblob_sentiment = "positive"
    elif polarity < -0.1: # and < -0.1 for negative
        textblob_sentiment = "negative"
    else:
        textblob_sentiment = "neutral"

    print(f"{review_text:<70} | {provided_sentiment:<20} | {polarity:<20.2f} | {textblob_sentiment:<20}")
```



Review Text	Provided Sentiment	TextBlob Polarity	TextBlob Sentiment
This product is absolutely amazing! I love it so much.	positive	0.48	positive
The features are fantastic and it works perfectly.	positive	0.70	positive
I am extremely happy with this purchase. Highly recommended!	positive	0.50	positive
What a terrible experience. The product broke after just one use.	negative	-1.00	negative
This is the worst item I have ever bought. Complete waste of money.	negative	-0.37	negative
I was so disappointed. It didn't meet my expectations at all.	negative	-0.75	negative
It's okay, but nothing special. Could be better.	neutral	0.45	positive
Good value for the price. I'm satisfied.	positive	0.60	positive
The customer service was awful and unhelpful.	negative	-1.00	negative
Really impressed with the quality and performance!	positive	1.00	positive
Meh, it's alright. Not great, not bad.	neutral	-0.03	neutral
Avoid this product at all costs! Seriously flawed.	negative	-0.50	negative
So glad I bought this! It has made my life easier.	positive	0.62	positive
The setup was confusing and the instructions were unclear.	negative	-0.30	negative
A solid product that does exactly what it says.	positive	0.12	positive

Textblob

```
▶ reviews_with_sentiment = [  
    ("This product is absolutely amazing! I love it so much.", "positive"),  
    ("The features are fantastic and it works perfectly.", "positive"),  
    ("I am extremely happy with this purchase. Highly recommended!", "positive"),  
    ("What a terrible experience. The product broke after just one use.", "negative"),  
    ("This is the worst item I have ever bought. Complete waste of money.", "negative"),  
    ("I was so disappointed. It didn't meet my expectations at all.", "negative"),  
    ("It's okay, but nothing special. Could be better.", "neutral"),  
    ("Good value for the price. I'm satisfied.", "positive"),  
    ("The customer service was awful and unhelpful.", "negative"),  
    ("Really impressed with the quality and performance!", "positive"),  
    ("Meh, it's alright. Not great, not bad.", "neutral"),  
    ("Avoid this product at all costs! Seriously flawed.", "negative"),  
    ("So glad I bought this! It has made my life easier.", "positive"),  
    ("The setup was confusing and the instructions were unclear.", "negative"),  
    ("A solid product that does exactly what it says.", "positive"),  
]  
  
print(f"{'Review Text':<70} | | {'Words':<20}")  
print("-" * 140)  
  
for review_text, provided_sentiment in reviews_with_sentiment:  
    # Create a TextBlob object  
    blob = TextBlob(review_text)  
  
    # Get the polarity score  
    t = blob.words  
  
    print(f"{'review_text':<70} | {t}")
```

Textblob



Review Text

| | Words

This product is absolutely amazing! I love it so much.
The features are fantastic and it works perfectly.
I am extremely happy with this purchase. Highly recommended!
What a terrible experience. The product broke after just one use.
This is the worst item I have ever bought. Complete waste of money.
I was so disappointed. It didn't meet my expectations at all.
It's okay, but nothing special. Could be better.
Good value for the price. I'm satisfied.
The customer service was awful and unhelpful.
Really impressed with the quality and performance!
Meh, it's alright. Not great, not bad.
Avoid this product at all costs! Seriously flawed.
So glad I bought this! It has made my life easier.
The setup was confusing and the instructions were unclear.
A solid product that does exactly what it says.

```
[ 'This', 'product', 'is', 'absolutely', 'amazing', 'I', 'love', 'it', 'so', 'much' ]  
[ 'The', 'features', 'are', 'fantastic', 'and', 'it', 'works', 'perfectly' ]  
[ 'I', 'am', 'extremely', 'happy', 'with', 'this', 'purchase', 'Highly', 'recommended' ]  
[ 'What', 'a', 'terrible', 'experience', 'The', 'product', 'broke', 'after', 'just', 'one', 'use' ]  
[ 'This', 'is', 'the', 'worst', 'item', 'I', 'have', 'ever', 'bought', 'Complete', 'waste', 'of', 'money' ]  
[ 'I', 'was', 'so', 'disappointed', 'It', 'did', 'n't', 'meet', 'my', 'expectations', 'at', 'all' ]  
[ 'It', 's', 'okay', 'but', 'nothing', 'special', 'Could', 'be', 'better' ]  
[ 'Good', 'value', 'for', 'the', 'price', 'I', 'm', 'satisfied' ]  
[ 'The', 'customer', 'service', 'was', 'awful', 'and', 'unhelpful' ]  
[ 'Really', 'impressed', 'with', 'the', 'quality', 'and', 'performance' ]  
[ 'Meh', 'it', 's', 'alright', 'Not', 'great', 'not', 'bad' ]  
[ 'Avoid', 'this', 'product', 'at', 'all', 'costs', 'Seriously', 'flawed' ]  
[ 'So', 'glad', 'I', 'bought', 'this', 'It', 'has', 'made', 'my', 'life', 'easier' ]  
[ 'The', 'setup', 'was', 'confusing', 'and', 'the', 'instructions', 'were', 'unclear' ]  
[ 'A', 'solid', 'product', 'that', 'does', 'exactly', 'what', 'it', 'says' ]
```

Textblob

Lemmatization

```
▶ from textblob import TextBlob
  from textblob.wordnet import VERB
  word = TextBlob("running").words[0]
  print(f"Plural of 'cat': {TextBlob('cat').words[0].pluralize()}")
  print(f"Lemma of 'running' (as a verb): {word.lemmatize(VERB)}")
  print(f"Lemma of 'mice': {TextBlob('mice').words[0].lemmatize()}")
  # Output:
  # Singular of 'octopi': octopus
  # Plural of 'cat': cats
  # Lemma of 'running' (as a verb): run
  # Lemma of 'mice': mouse
```

```
⇒ Plural of 'cat': cats
   Lemma of 'running' (as a verb): run
   Lemma of 'mice': mouse
```

Introduction aux Données Hiérarchiques

Diapositive 1 — Structures de Données Relationnelles en Science des Données

💡 Les données hiérarchiques représentent des relations où les éléments sont connectés dans une structure **parent-enfant** ou **tout-partie**. C'est l'une des formes relationnelles les plus courantes en science des données.

🏗️ Caractéristiques Clés

Organisation en **niveaux**, débutant par un nœud "racine".

La racine se ramifie vers des nœuds intermédiaires puis vers des "feuilles" (terminaux).

Définition formelle : Graphe **connexe, non pondéré et acyclique**.

Profondeur : Distance du nœud terminal le plus éloigné.

Degré de branchement (fan-out) : Nombre d'enfants d'un parent.

📁 Exemples Concrets

📁 **Systèmes de Fichiers**
Dossiers contenant sous-dossiers et fichiers.

🧬 **Biologie Évolutive**
Arbres phylogénétiques et classification.

🏢 **Organigrammes**
Structures de reporting en entreprise.

🏆 **Tableaux de Tournoi**
Appariements compétitifs.

👁️ Types de Visualisations


Nœud-Lien : Arbres traditionnels.

Remplissage d'Espace :



Treemaps

Sunbursts

Cone Trees



Node link Tree



Tree maps: Use nested rectangles to represent levels. The area of each rectangle often corresponds to a quantitative value (e.g., file size).

- ## How to interpret it

-
- ```

graph LR
 SM[Stock Market] --- Tech[Technology]
 SM --- Fin[Finance]
 SM --- HC[Healthcare]
 Tech --- Apple[Apple]
 Tech --- MS[Microsoft]
 Tech --- Nvidia[Nvidia]
 Fin --- JPM[JPMorgan]
 Fin --- BOA[Bank of America]
 HC --- Pfizer[Pfizer]
 HC --- Lilly[Lilly]

```
- Stock Market
- Technology
    - Apple
    - Microsoft
    - Nvidia
  - Finance
    - JPMorgan
    - Bank of America
  - Healthcare
    - Pfizer
    - Lilly



# SunBurst

Sunburst / InterRing: Radial space-filling techniques. The root is in the center, and is drawn as concentric rings or segments surrounding it.


How to interpret it

- Center circle → root node (the website).
- First ring → main categories (Products, Services, About).
- Outer rings → deeper levels (Electronics → Phones → specific models).
- Arc size → proportion of traffic or content size.

Why this visualization works

Sunburst charts help when:

- You want to visualize hierarchical depth
- You want to show how categories break into subcategories.
- You want a compact radial layout.



The text highlights several specialized toolkits and libraries designed to handle the complex layout algorithms required for trees and graphs:

- Graphviz: A long-standing library of graph layout algorithms that uses the DOT language to describe structures and render them into various formats.
- Prefuse: A Java-based toolkit that implements the information visualization reference model, supporting TreeML and GraphML file formats for hierarchical data.
- XmdvTool: A research-oriented tool that includes specialized hierarchical features like "structure-based brushes" and the InterRing radial display.
- Gephi/Tableau/Spotfire: Modern commercial and open-source platforms that provide robust, interactive environments for exploring large networks and hierarchies