

Projet d'Évaluation

Partie 1 : Les Chroniques Météo de Melbourne (Lab 7)

Description

Nous sommes en 1990. Vous avez été engagé par le Bureau Météorologique de Melbourne pour numériser et analyser une décennie de données climatiques. La ville est célèbre pour ses « quatre saisons en une journée », et le Bureau cherche un moyen de rendre cette volatilité compréhensible pour le public.

On vous remet un registre usé contenant les « **Températures minimales quotidiennes à Melbourne** ». Votre mission est de construire une « Machine à remonter le temps météo » interactive à l'aide de **Bokeh**. Avant de pouvoir la bâtir, vous devez « nettoyer » le registre : supprimer les points de données manquants (marqués par un « ? ») et vous assurer que les dates sont reconnues comme un flux temporel linéaire.

Questions

Question 1 : Graphique linéaire de série temporelle de base

1. Créez un graphique linéaire simple montrant la température minimale quotidienne au fil du temps.
 - a. Utilisez la colonne 'Date' pour l'axe x et 'Temperature' pour l'axe y.
 - b. Titrez le graphique : "Daily Minimum Temperatures".
 - c. Nommez l'axe x "Date" et l'axe y "Temperature (°C)".
 - d. Ajoutez des bulles d'aide (tooltips) pour afficher la date et la température au survol de la ligne.
 - e. Activez les outils de déplacement (pan), de zoom à la molette (wheel zoom) et de réinitialisation (reset).

Question 2 : Moyenne mobile 2. Calculez la moyenne mobile sur 30 jours de la température minimale quotidienne et tracez-la aux côtés des données originales.

- Créez une nouvelle colonne 'Rolling_Avg' dans le DataFrame contenant cette moyenne.
- Tracez à la fois la température originale ('Temperature') et la moyenne mobile ('Rolling_Avg') sur le même graphique.
- Utilisez des couleurs et des styles de ligne différents pour les distinguer.
- Ajoutez une légende pour identifier les lignes.

- Ajoutez des tooltips pour afficher la date, la température d'origine et la moyenne mobile.

Question 3 : Boîtes à moustaches (Box Plots) mensuelles 3. Créez des diagrammes en boîte pour visualiser la distribution des températures pour chaque mois.

- Extrayez le mois de la colonne 'Date' et créez une nouvelle colonne 'Month'.
- Groupez les données par mois et préparez-les pour le tracé.
- Utilisez les éléments de box plot de Bokeh pour visualiser la distribution.
- Étiquetez l'axe x avec les noms des mois et l'axe y avec "Temperature (°C)".
- Ajoutez des tooltips pour afficher le mois et les valeurs statistiques (min, max, médiane).

Question 4 : Analyse annuelle et cartographie des couleurs 4. Créez des box plots pour visualiser la distribution des températures pour chaque année et utilisez une cartographie de couleurs pour mettre en évidence les variations.

- Extrayez l'année de la colonne 'Date' et créez une nouvelle colonne 'Year'.
- Utilisez `factor_cmap` pour colorer les boîtes en fonction de la température médiane de chaque année.
- Ajoutez des tooltips pour afficher l'année et les valeurs statistiques (min, max, médiane, etc.).
- Activez les outils de déplacement, de zoom et de réinitialisation.

Question 5 : Sélection interactive de la plage temporelle 5. Créez un graphique linéaire interactif où l'utilisateur peut sélectionner une période spécifique à l'aide d'un curseur de plage de dates (date range slider).

- Implémentez un curseur de plage de dates à l'aide des widgets Bokeh.
- Mettez à jour le graphique dynamiquement en fonction de la plage sélectionnée.
- Ajoutez des tooltips et activez les outils de navigation habituels.

Question 6 : Visualisation de la décomposition de série temporelle 6. Effectuez une décomposition simple pour visualiser la tendance et la saisonnalité des données.

- Rééchantillonnez les données à une fréquence mensuelle (moyenne mensuelle).
- Utilisez une moyenne mobile simple pour estimer la composante de **tendance**.
- Calculez la **composante saisonnière** en soustrayant la tendance des données mensuelles originales.
- Créez trois graphiques Bokeh séparés et alignés partageant le même axe x (Date) : données mensuelles, tendance et saisonnalité.

Partie 2 : La Voix du Consommateur (Lab 10)

Description

Passons à l'ère moderne. Vous êtes maintenant Data Scientist pour une grande plateforme d'e-commerce qui vient de franchir une étape clé : **20 000 avis produits**. Bien que les notes étoilées donnent une idée du succès, le PDG veut savoir ce que les clients disent *réellement*.

Le texte brut est confus : rempli de fautes de frappe, d'argot et de mots de remplissage. Vous devez construire une **Raffinerie NLP** pour éliminer le bruit. L'objectif est d'effectuer une analyse de sentiment et de réduire chaque mot à son « lemme » (sa forme dictionnaire) afin de révéler les tendances cachées des retours clients.

Tâches Techniques

1. Effectuez une analyse de sentiment sur la collection d'avis, classez chacun comme 'positif', 'négatif' ou 'neutre', puis générez un graphique à barres pour visualiser la distribution de ces sentiments.
2. Convertissez le texte en minuscules, supprimez la ponctuation et les chiffres, filtrez les mots vides (stopwords) courants, puis lemmatisez les mots restants en utilisant les étiquettes de catégories grammaticales (part-of-speech tags) appropriées.
3. Une fois le texte prétraité et lemmatisé, calculez la fréquence de chaque mot unique et affichez un graphique à barres montrant les 15 mots les plus fréquents.
4. Générez un nuage de mots (word cloud) basé sur l'ensemble du corpus de mots lemmatisés pour fournir un résumé visuel des termes les plus proéminents.
5. Visualisez la fréquence des noms, des verbes et des adjectifs dans ce texte.

Note importante sur les données : Vous trouverez les fichiers de données nécessaires dans le dossier datasets/ de la branche principale (**main branch**) du dépôt.

Consignes de rendu : Les réponses doivent être soumises dans les trois formats suivants : **.pdf**, **.ipynb** (Notebook Jupyter) et **.html**. Au moins l'un de ces formats doit impérativement afficher toutes les figures et visualisations de manière correcte et lisible.



Date limite de soumission : 30 mars 2026.