Introduction : Analyse du jeu de données MPG

Dans ce tutoriel, nous allons explorer en détail le jeu de données "mpg". Ce jeu de données, initialement publié par la bibliothèque StatLib de l'Université Carnegie Mellon et désormais disponible dans la bibliothèque Seaborn. L'objectif de ce tutoriel est d'explorer la relation entre la consommation de carburant (Miles Per Gallon, ou MPG) et diverses autres caractéristiques de ce jeu de données.

Le jeu de données "mpg" est particulièrement intéressant pour notre étude car il présente une combinaison de caractéristiques discrètes et continues. Il contient :

- 3 caractéristiques discrètes : Ces variables catégorielles nous permettront d'analyser des groupes ou des classifications au sein des données.
- 5 caractéristiques continues : Ces variables numériques nous permettront d'examiner des relations et des tendances quantitatives.

In [18]:
```
import seaborn as sns
import plotly.express as px

# Chargement du dataset MPG
mpg_df = sns.load_dataset("mpg")
mpg_df = mpg_df.dropna()

print(mpg_df.shape)
mpg_df.head()
```

```
(392, 9)
```

Out[18]:

	mpg	cylinders	displacement	horsepower	weight	acceleration	model_year	orig
0	18.0	8	307.0	130.0	3504	12.0	70	us
1	15.0	8	350.0	165.0	3693	11.5	70	us
2	18.0	8	318.0	150.0	3436	11.0	70	us
3	16.0	8	304.0	150.0	3433	12.0	70	us
4	17.0	8	302.0	140.0	3449	10.5	70	us

In [19]:
```
mpg_df.describe()
```

Out[19]:

	mpg	cylinders	displacement	horsepower	weight	acceleratior
count	392.000000	392.000000	392.000000	392.000000	392.000000	392.000000
mean	23.445918	5.471939	194.411990	104.469388	2977.584184	15.541327
std	7.805007	1.705783	104.644004	38.491160	849.402560	2.758864
min	9.000000	3.000000	68.000000	46.000000	1613.000000	8.000000
25%	17.000000	4.000000	105.000000	75.000000	2225.250000	13.775000
50%	22.750000	4.000000	151.000000	93.500000	2803.500000	15.500000
75%	29.000000	8.000000	275.750000	126.000000	3614.750000	17.025000
max	46.600000	8.000000	455.000000	230.000000	5140.000000	24.800000

Scatter Plots

Les scatter plots (nuages de points) permettent de visualiser la **relation entre deux variables continues**. Un point est affiché pour chaque observation, dont la position correspond aux valeurs des deux variables. On peut enrichir le graphique avec une troisième dimension via la couleur ou la taille des points.

In [20]:

```
# Scatter plot : MPG vs Poids, coloré par origine
fig1 = px.scatter(mpg_df, x='weight', y='mpg', color='origin',
                  title='MPG en fonction du poids')
fig1.show()
```

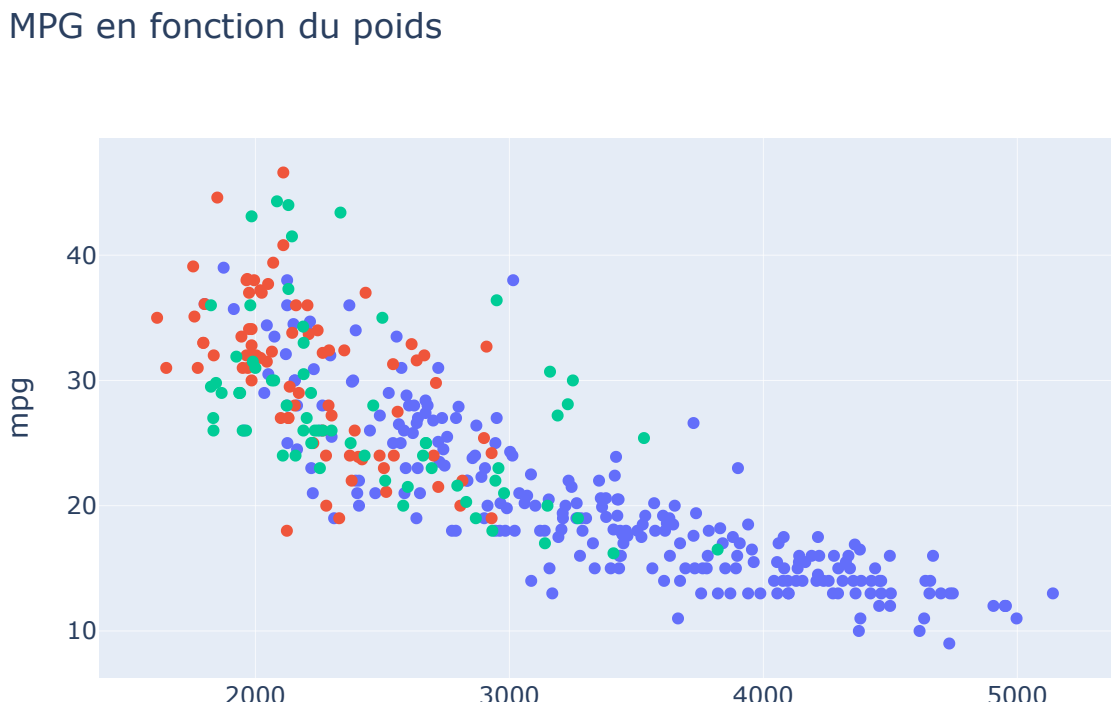

In [21]:
```
# Scatter plot : MPG vs Puissance, coloré par nombre de cylindres
fig2 = px.scatter(mpg_df, x='horsepower', y='mpg', color='cylinders',
                  title='MPG en fonction de la puissance')
fig2.show()
```

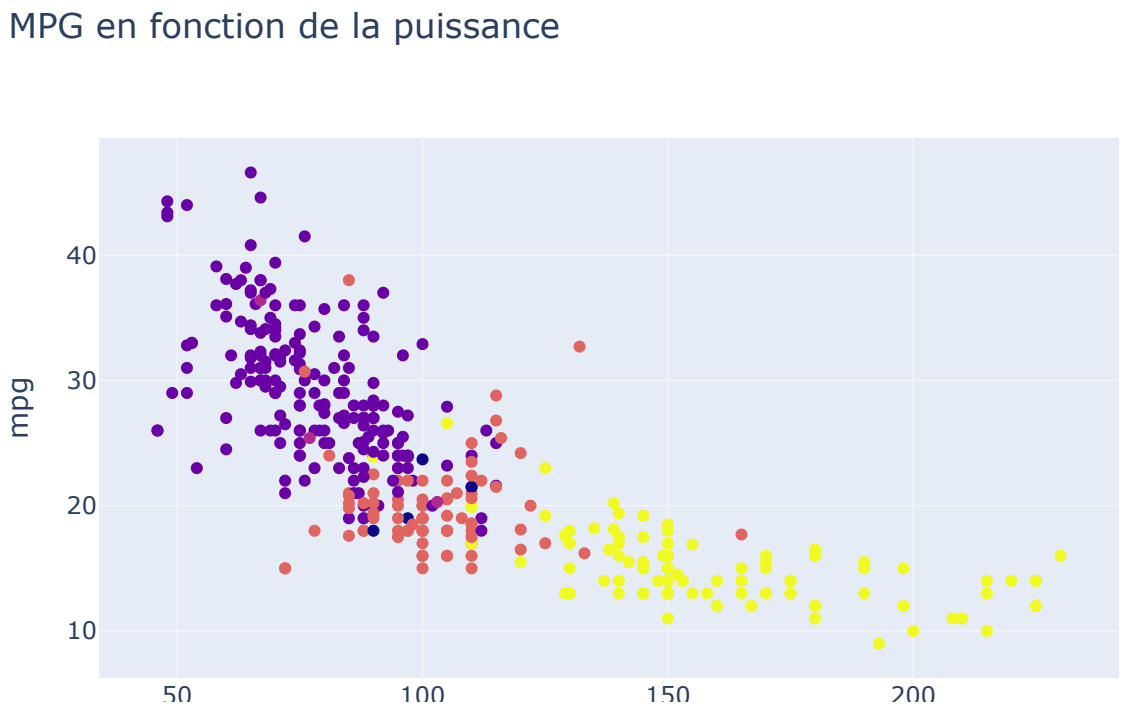

Line Plots

Les line plots (graphiques en courbes) permettent de visualiser **l'évolution d'une variable dans le temps** ou selon un axe ordonné. Ils sont particulièrement utiles pour repérer des tendances et des changements au fil des années.

In [22]:
```
# Line plot : évolution de la consommation moyenne par année
mpg_by_year = mpg_df.groupby('model_year')['mpg'].mean().reset_index()

fig3 = px.line(mpg_by_year, x='model_year', y='mpg', markers=True,
               title='Consommation moyenne (MPG) par année')
fig3.show()
```

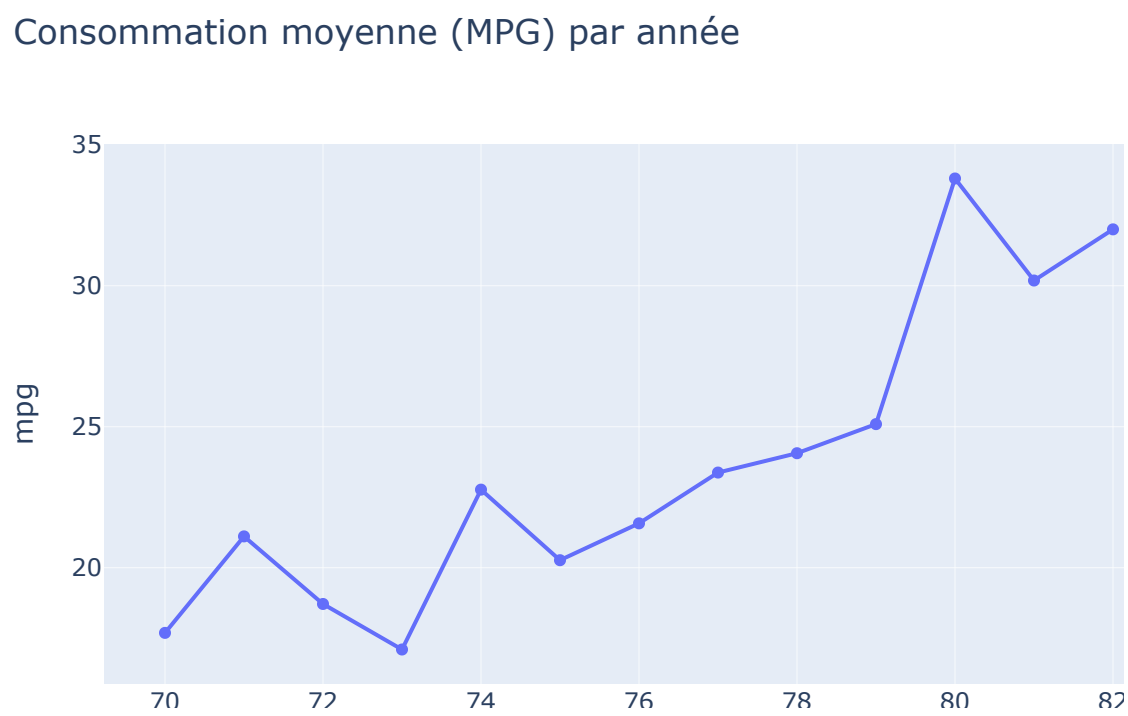

In [ ]:
```
# Line plot : évolution par année et par origine
mpg_by_year_origin = mpg_df.groupby(['model_year', 'origin'])['mpg'].mean().

fig4 = px.line(mpg_by_year_origin, x='model_year', y='mpg', color='origin',
               title='Consommation moyenne (MPG) par année et origine')
fig4.show()
```

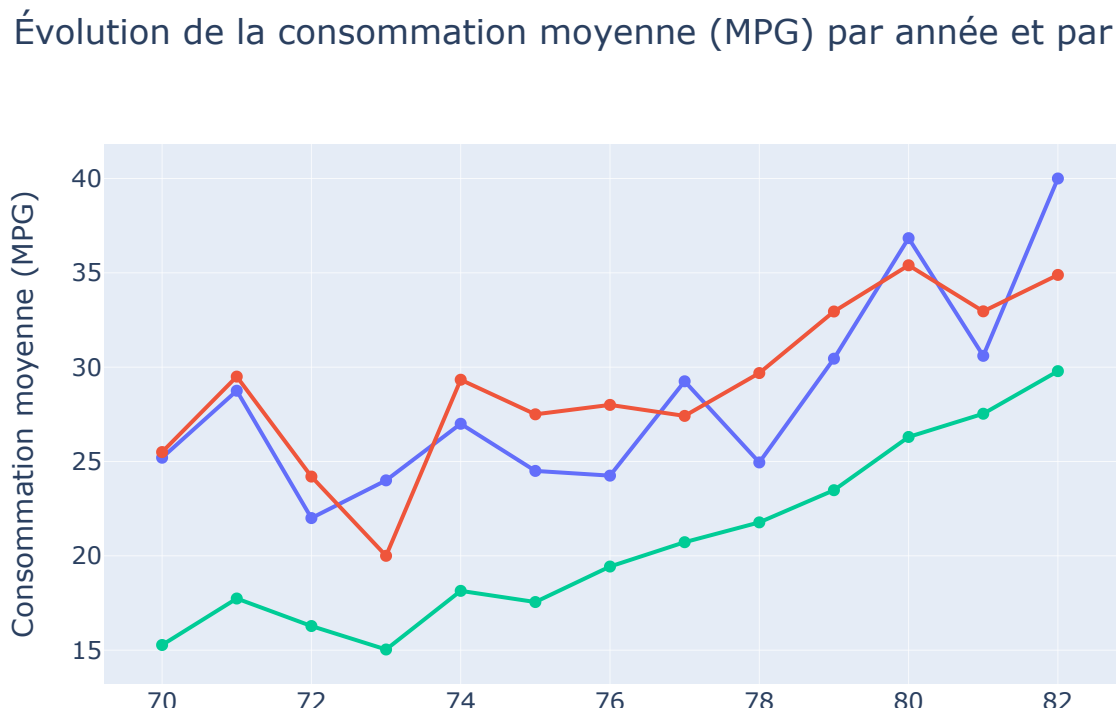

Heatmaps

Les heatmaps (cartes de chaleur) permettent de visualiser **une matrice de valeurs** via des couleurs. Elles sont particulièrement utilisées pour afficher les **corrélations** entre variables : une couleur chaude indique une forte corrélation positive, une couleur froide indique une corrélation négative.

In [24]:
```
# Heatmap : matrice de corrélation
corr = mpg_df[['mpg', 'cylinders', 'displacement', 'horsepower', 'weight', '

fig5 = px.imshow(corr, text_auto='.2f', color_continuous_scale='RdBu_r', zmi
                 title='Matrice de corrélation')
fig5.show()
```

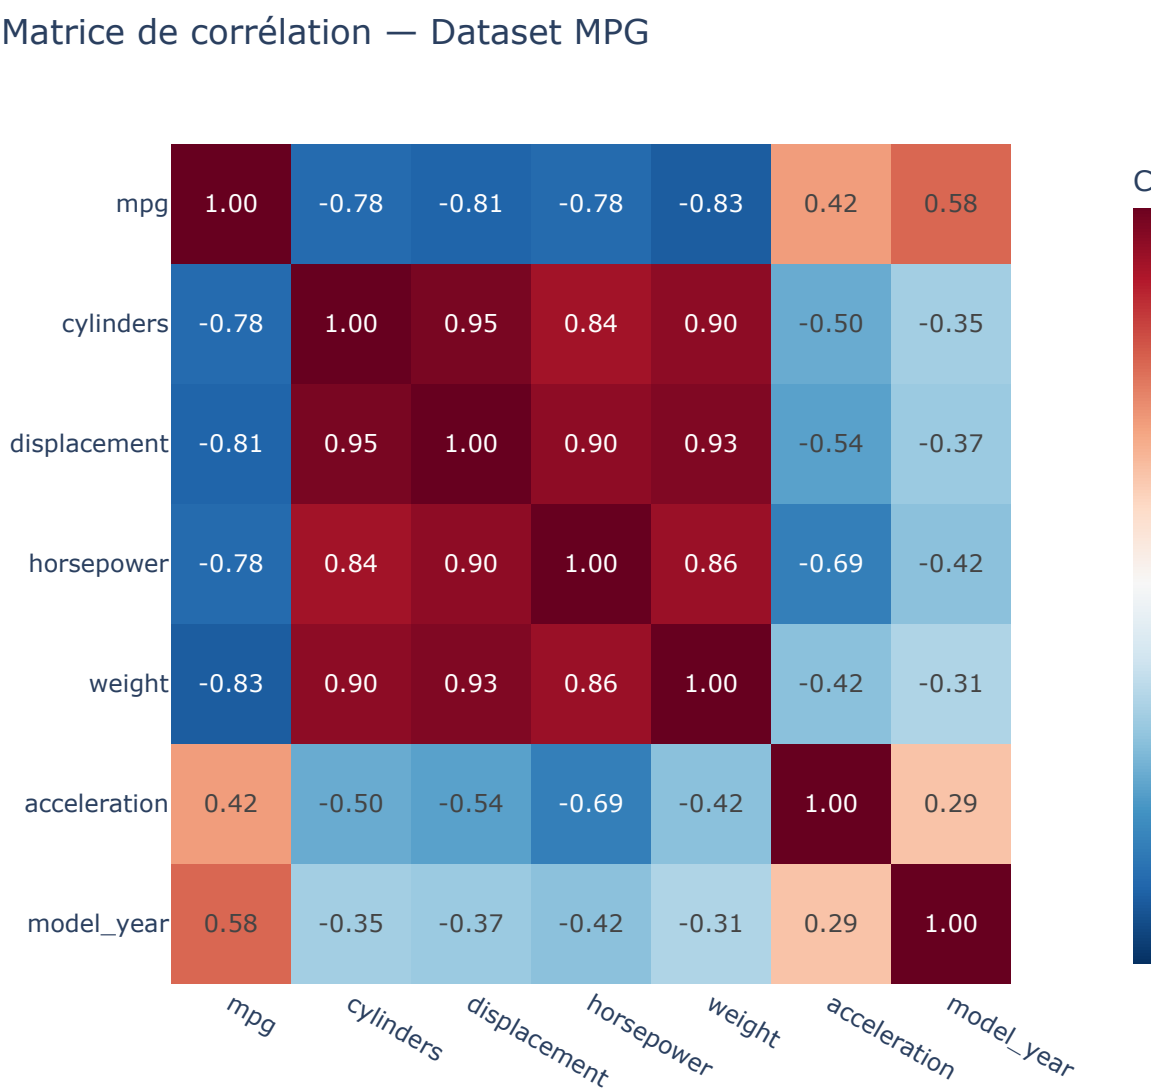

In [ ]:
```
# Heatmap : MPG moyen par origine et nombre de cylindres
pivot = mpg_df.groupby(['origin', 'cylinders'])['mpg'].mean().unstack()

fig6 = px.imshow(pivot, text_auto='.1f', color_continuous_scale='Viridis',
                 title='MPG moyen par origine et cylindres')
fig6.show()
```

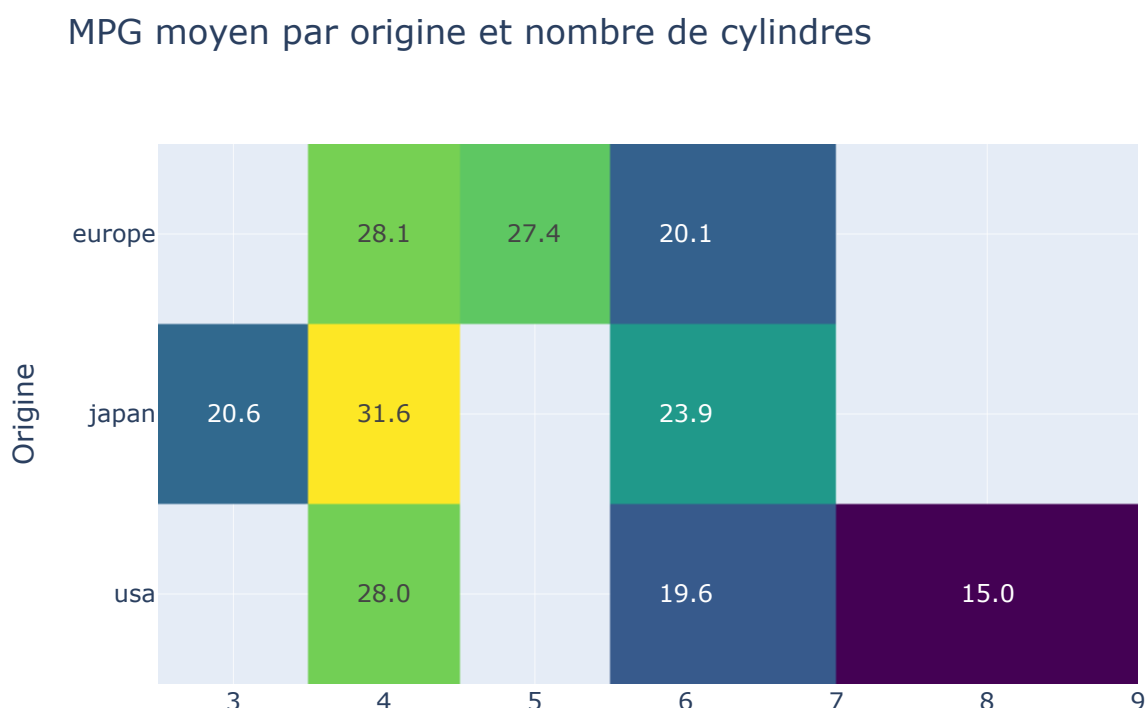
MPG moyen par origine et nombre de cylindres
Origine
europe
japan
usa
28.1
27.4
20.1
20.6
31.6
23.9
28.0
19.6
15.0
3
4
5
6
7
8
9